INSTITUTO TECNOLÓGICO Y DE ESTUDIOS SUPERIORES DE MONTERREY

Maestría en Inteligencia Artificial Aplicada (MNA)

Proyecto Integrador

Sistema multi-agente de auditoría (ISO 27001)

Avance 2. Ingeniería de características

Profesor: Dra. Grettel Barceló Alonso

Profesor: Dr. Luis Eduardo Falcón Morales

Equipo 16

Joel Alonso Vázquez	A01796712
Roberto López Baldomero	A01653630
David Sánchez Almanza	A01210766

17 de mayo de 2026

Avance 2. Ingeniería de características 4
Objetivos 4
Introducción 4
Catálogo de Datos del Proyecto 5
A. Operaciones de Ingeniería de Características 6
A.1 Generación de Nuevas Características 6
A.1.1 Metadatos Estructurales del Documento 6
A.1.2 Características semánticas derivadas 7
A.1.3 Características Estadísticas del Texto 7
A.2 Discretización y Binning 8
A.2.1 Discretización de Longitud de Chunk 8
A.2.2 Discretización de Densidad de Keywords 9
A.2.3 Discretización de Legibilidad 9
A.3 Codificación 9
A.3.1 Codificación Ordinal 9
A.3.2 Codificación One-Hot 10
A.4 Escalamiento 10
A.4.1 Normalización L2 de Embeddings 11
A.4.2 Estandarización (Z-score) de Características Numéricas 11
A.4.3 Min-Max Scaling para Scores de Relevancia 11
A.5 Transformaciones 12
A.5.1 Transformación Logarítmica 12
A.6 Estrategias de Chunking en Amazon Bedrock Knowledge Bases 13
A.6.1 Chunking Semántico 13
A.6.2 Chunking Jerárquico (Para documentos estructurados) 13
A.6.3 Mapeo de Estrategias por Tipo de Documento 14
B. Selección y Extracción de Características 14
B.1 Métodos de Filtrado para Selección de Características 15
B.1.1 Umbral de Varianza 15
B.1.2 Correlación 15
B.1.3 Chi-Cuadrado (χ^2) 17
B.1.4 ANOVA (Análisis de Varianza) 18
B.2 Técnicas de Extracción de Características 19
B.2.1 Análisis de Componentes Principales (PCA) 19
B.2.2 Análisis Factorial (FA) 20
B.3 Técnicas Adicionales Aplicadas 23
B.3.1 Deduplicación Semántica de Chunks 23
B.3.2 Filtrado por Contenido Informativo 24
C. Conclusiones de la Fase de Preparación de Datos 25
C.1 Resumen de la Fase en el Contexto CRISP-ML(Q) 25

C.2 Hallazgos Principales 25
C.3 Riesgos Identificados y Mitigación 28
C.4 Alineación con Objetivos del Proyecto 29
C.5 Métricas de Calidad de la Fase 30
C.6 Consideraciones para la Siguiente Fase 31
C.7 Cumplimiento de Instrucciones del Avance 2 31
Referencias 33
Metodología CRISP-ML(Q) y Machine Learning 33
Feature Engineering y Selección de Características 33
Transformaciones y Análisis Estadístico 33
Procesamiento de Lenguaje Natural y Embeddings 33
Retrieval-Augmented Generation (RAG) 33
Chunking Strategies 34
Documentación de AWS 34
Normativas y Estándares ISO 35
Herramientas 35

Avance 2. Ingeniería de características

Objetivos

- 2.3 Crear nuevas características para mejorar el rendimiento de los modelos.
- 2.4 Mitigar el riesgo de características sesgadas y acelerar la convergencia de algunos algoritmos.

Introducción

La fase de Ingeniería de Características (Feature Engineering) constituye un paso crítico dentro de la metodología CRISP-ML(Q), específicamente en la etapa de Data Engineering (Data Preparation). Según Studer et al. (2021), esta fase tiene como objetivo transformar los datos crudos en un conjunto de variables útiles para el aprendizaje automático, mitigando riesgos como el sesgo en las características y acelerando la convergencia de los algoritmos.

En el contexto de nuestro proyecto, un sistema multi-agente basado en Retrieval-Augmented Generation (RAG) para auditorías ISO 27001, la ingeniería de características adquiere una dimensión particular. A diferencia de los proyectos de ML tabulares tradicionales, nuestro pipeline opera sobre datos textuales no estructurados que conforman la base de conocimiento del sistema. Por lo tanto, las técnicas de feature engineering se adaptan al dominio del procesamiento de lenguaje natural (NLP) y a los requerimientos específicos de los sistemas RAG implementados con Amazon Bedrock Knowledge Bases.

Arquitectura de Datos del Proyecto

El sistema utiliza los siguientes servicios de AWS para la gestión y procesamiento de datos:

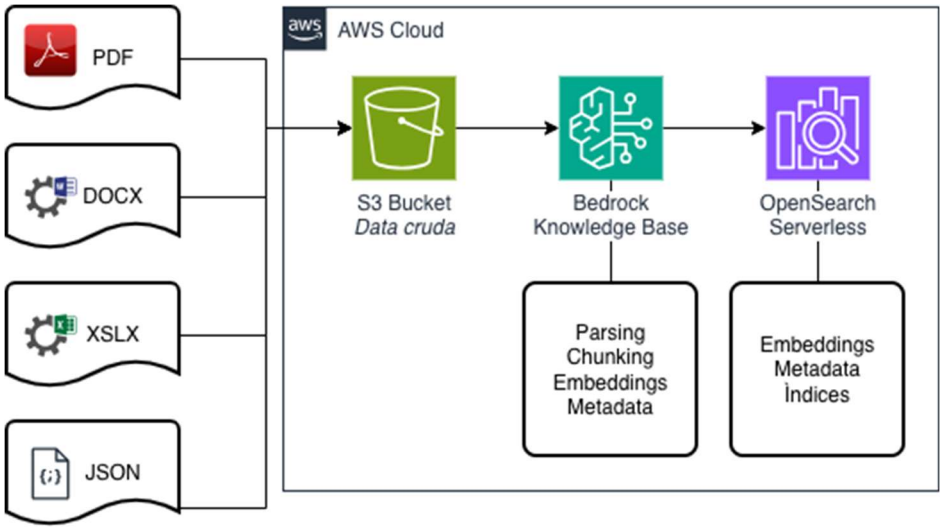


Imagen 1. Arqtuitectura de datos

Catálogo de Datos del Proyecto

1. Base de conocimiento principal

Categoría	Archivos	Formato	Descripción
iso27001/	1	PDF	Norma ISO/IEC 27001:2013 completa
audit-examples/	8	PDF, DOCX	Reportes de auditoría reales anonimizados
audit-methodology/	4	PDF	Metodología ISO 19011, guías de auditoría
ciso-assistant-community/	5	YAML	Frameworks estructurados (ISO 27001:2022, ISO 22301, ISO 42001)
non-conformities/	1	MD	Catálogo de no conformidades comunes
sponsor-documents/	8	PDF, DOCX	Políticas organizacionales del sponsor

2. ISO 27001:2022 Toolkit (ISO-27001-2022-Toolkit/)

Carpeta	Archivos	Formato	Propósito
Gap Assessment Plan	2	XLSX, DOCX	Evaluación de brechas
SOA	1	XLSX	Statement of Applicability
Risk Register	2	XLSX, DOCX	Registro de riesgos
Scope and Context	1	DOCX	Definición de alcance
Asset Inventory	1	XLSX	Inventario de activos
BCP/DRP	2	DOCX	Continuidad y recuperación
Security Policy	1	DOCX	Políticas de seguridad
Training Plan	1	DOCX	Plan de capacitación
Management Review	2	XLSX, DOCX	Revisión por dirección
ISMS Checklists	3	DOCX	Listas de verificación
Internal Audit	2	XLSX, DOCX	Auditoría interna
ROI	1	DOCX	Retorno de inversión

3. Datos Adicionales (data/)

Archivo	Formato	Contenido
Requisitos_Norma_ISO_19011-2011.pdf	PDF	Requisitos de auditoría
IEEG-Resultados de auditoria en madurez TI.pdf	PDF	Ejemplo de resultados
Planeación de Auditoria-PREP.pdf	PDF	Plantilla de planeación
PLEXUS-Diagnostico_PSS_IAFT16949.pdf	PDF	Diagnóstico de ejemplo

Flujo de Feature Engineering utilizando Amazon Bedrock Knowledge Bases

El proceso de ingeniería de características en nuestro sistema RAG se muestra en el siguiente flujo:

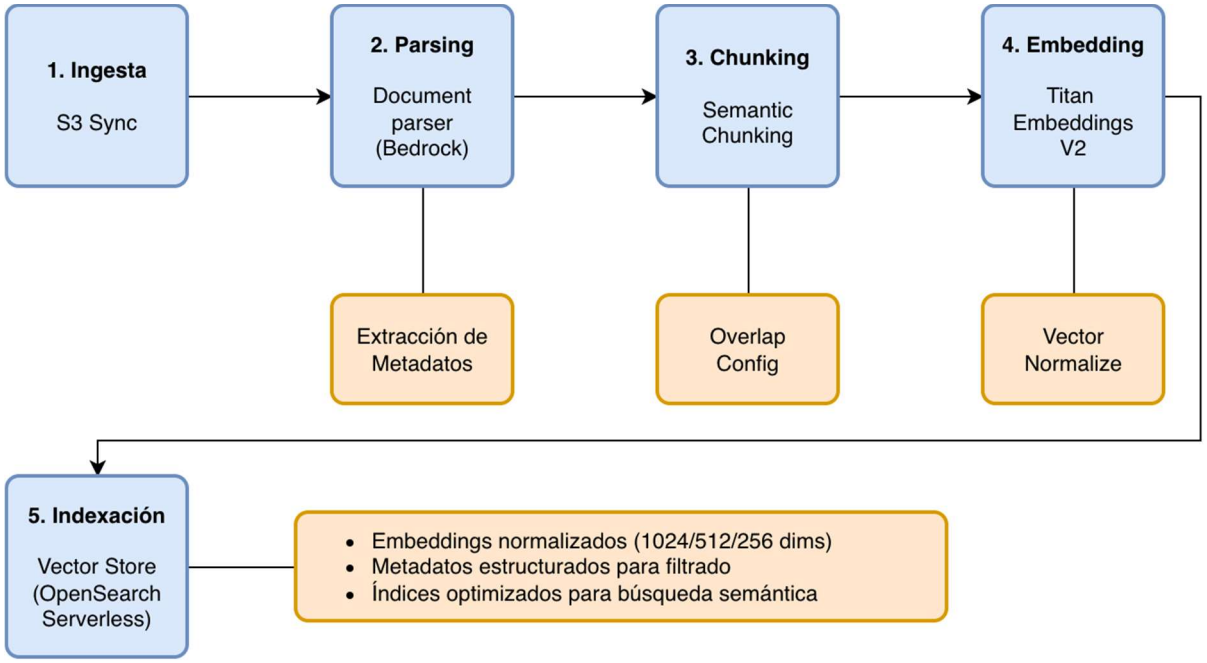


***Imagen 2**. Pipeline de datos para Feature Engineering*

A. Operaciones de Ingeniería de Características

En esta sección se detallan las operaciones aplicadas para convertir los datos crudos del proyecto en un conjunto de variables útiles para el sistema RAG de auditoría ISO 27001, utilizando Amazon Bedrock Knowledge Bases como plataforma principal.

A.1 Generación de Nuevas Características

En un sistema RAG implementado con Amazon Bedrock Knowledge Bases, la generación de características se centra en enriquecer los fragmentos de texto (chunks) con metadatos que mejoren la recuperación y la relevancia contextual. Las nuevas características generadas para nuestro proyecto incluyen:

A.1.1 Metadatos Estructurales del Documento

Cada documento almacenado en S3 se acompaña de un archivo de metadatos JSON (.metadata.json) que contiene:

```
{
  "metadataAttributes": {
    "document_type": "audit_report",
    "source_category": "audit-examples",
    "iso_control_reference": "A.5.1",
    "document_language": "en",
    "temporal_relevance": "current",
    "compliance_domain": "organizational_controls"
  }
}
```

Metadatos estructurales del documento:

- document_type: Clasificación del tipo de documento (norma ISO, reporte de auditoría, política organizacional, guía metodológica, no conformidad).
- source_category: Categoría de origen dentro de la base de conocimiento (iso27001, audit-examples, audit-methodology, non-conformities, sponsor-documents, ciso-assistant-community).
- section_hierarchy: Jerarquía de secciones dentro del documento original (e.g., "Cláusula 6 > 6.1 > 6.1.2").
- iso_control_reference: Referencia al control ISO 27001 específico cuando aplica (e.g., "A.5.1", "A.8.2").

A.1.2 Características semánticas derivadas

Las características semánticas se derivan mediante técnicas de procesamiento de lenguaje natural:

- chunk_topic: Representa el tópico dominante del fragmento. Se extrae mediante topic modeling con LDA (Latent Dirichlet Allocation) entrenado sobre el corpus ISO 27001, permitiendo identificar automáticamente el tema principal de cada chunk.
- compliance_domain: Indica el dominio de cumplimiento según ISO 27001:2022. Se determina mediante clasificación basada en los 4 temas del Anexo A, asignando cada chunk al dominio más relevante.
- document_language: Identifica el idioma del documento fuente (español o inglés). Se obtiene mediante detección automática utilizando la biblioteca langdetect, lo cual es relevante para el procesamiento multilingüe del sistema.
- temporal_relevance: Indica la vigencia normativa del contenido. Se asigna mediante mapeo directo donde los documentos basados en ISO 27001:2013 reciben el valor "legacy" y los basados en la versión 2022 reciben "current".

Dominios de cumplimiento ISO 27001:2022 (Anexo A):

El Anexo A de ISO 27001:2022 organiza los controles en cuatro dominios principales:

- A.5 - Controles Organizacionales: Comprende 37 controles relacionados con políticas, roles y responsabilidades. En el proyecto, los documentos relacionados incluyen Information Security Policy y Scope.docx.
- A.6 - Controles de Personas: Incluye 8 controles sobre competencia, concientización y capacitación del personal. El documento Awareness and Training Plan.docx del toolkit corresponde a este dominio.
- A.7 - Controles Físicos: Contiene 14 controles sobre seguridad física y ambiental. El Business Continuity Plan.docx aborda aspectos de este dominio.
- A.8 - Controles Tecnológicos: Agrupa 34 controles sobre seguridad de sistemas y datos. Los documentos Disaster Recovery Plan.docx y Asset Inventory.xlsx se relacionan principalmente con este dominio.

A.1.3 Características Estadísticas del Texto

Estas características se generan durante el proceso de chunking en Amazon Bedrock:

- chunk_length: Mide la longitud del fragmento en tokens utilizando el tokenizer de Amazon Titan. El rango típico observado en el proyecto es de 50 a 512 tokens, dependiendo de la estrategia de chunking configurada.
- sentence_count: Cuenta el número de oraciones por chunk mediante segmentación por puntuación. Los valores típicos oscilan entre 1 y 15 oraciones por fragmento.
- keyword_density: Calcula la proporción de términos del dominio ISO 27001 respecto al total de tokens, mediante la fórmula (términos_ISO / total_tokens). Los valores típicos van de 0.01 a 0.08.
- readability_score: Evalúa la legibilidad del fragmento usando el índice Flesch-Kincaid Grade Level. Los documentos técnicos del proyecto presentan valores entre 12 y 18, indicando contenido de nivel universitario o profesional.

La generación de metadatos estructurales y semánticos permite a Amazon Bedrock Knowledge Bases realizar filtrado previo a la búsqueda vectorial (metadata filtering), mejorando la precisión de la recuperación. Según la documentación de AWS, el filtrado por metadatos reduce el espacio de búsqueda y mejora la relevancia de los resultados (AWS Documentation, 2024).

A.2 Discretización y Binning

Se aplica discretización a las características numéricas continuas para facilitar su uso como filtros categóricos en Amazon Bedrock Knowledge Bases.

A.2.1 Discretización de Longitud de Chunk

La longitud de los chunks se discretiza en tres categorías:

- short (< 128 tokens): Corresponde a contenido breve como definiciones, glosarios y elementos de referencia rápida. En el proyecto, el catálogo de no conformidades genera principalmente chunks de esta categoría.
- medium (128-384 tokens): Representa el rango óptimo para controles ISO, procedimientos y contenido estructurado. Los documentos SOA y Risk Register producen chunks en este rango.
- long (> 384 tokens): Incluye narrativas extensas y reportes completos que requieren mayor contexto. Los reportes de auditoría y el Business Continuity Plan generan chunks largos.

Configuración en Amazon Bedrock:

```
chunking_configuration = {
    "chunkingStrategy": "FIXED_SIZE",
    "fixedSizeChunkingConfiguration": {
        "maxTokens": 512,
        "overlapPercentage": 20
    }
}
```

A.2.2 Discretización de Densidad de Keywords

La densidad de términos clave ISO 27001 se categoriza en tres niveles:

- low (< 0.02): Indica texto general o contextual con baja concentración de terminología específica del dominio. Estos chunks proporcionan contexto pero no son altamente específicos.

- medium (0.02-0.05): Representa contenido mixto que combina terminología técnica con explicaciones generales. Es el rango más común en documentos de políticas y procedimientos.
- high (> 0.05): Señala alta concentración terminológica ISO, típica de definiciones de controles, requisitos normativos y checklists de auditoría.

Vocabulario de keywords ISO 27001 utilizado:

```
iso_keywords = [
    "control", "risk", "asset", "threat", "vulnerability",
    "confidentiality", "integrity", "availability", "ISMS",
    "audit", "non-conformity", "corrective action", "policy",
    "procedure", "evidence", "clause", "annex", "statement of applicability"
]
```

A.2.3 Discretización de Legibilidad

El índice de legibilidad Flesch-Kincaid se discretiza según la audiencia objetivo:

- technical (> 14): Contenido altamente técnico dirigido a auditores expertos y especialistas en seguridad de la información. Requiere conocimiento previo del dominio.
- intermediate (10-14): Contenido accesible para personal de TI y profesionales con formación técnica general. Incluye la mayoría de procedimientos y guías.
- accessible (< 10): Contenido diseñado para usuarios generales sin formación técnica especializada. Incluye políticas de alto nivel y material de concientización.

La discretización permite utilizar estas características como filtros categóricos en las consultas de recuperación de Amazon Bedrock, reduciendo el espacio de búsqueda. Según Zheng & Casari (2018), la discretización es particularmente útil cuando la relación entre la variable continua y el objetivo no es lineal.

A.3 Codificación

La codificación se aplica a los metadatos categóricos que acompañan a cada chunk en el vector store.

A.3.1 Codificación Ordinal

Para variables con orden inherente se aplica codificación ordinal:

- temporal_relevance: Se codifica como {obsolete: 0, legacy: 1, current: 2}, reflejando la jerarquía de vigencia normativa. Los documentos basados en versiones anteriores de ISO 27001 reciben valores menores.
- section_depth: Se codifica como {level_1: 0, level_2: 1, level_3: 2, level_4: 3}, representando la profundidad en la estructura documental. Las secciones principales tienen valores bajos mientras que las subsecciones detalladas tienen valores altos.
- audit_phase: Se codifica como {planning: 0, execution: 1, reporting: 2, followup: 3}, siguiendo la secuencia natural del proceso de auditoría según ISO 19011.

Aplicación a datos del proyecto:

```
document_mappings = {
    "iso-iec-27001-2013-en.pdf": {"temporal_relevance": 1},  # legacy
```

```
    "iso27001-2022.yaml": {"temporal_relevance": 2},         # current
    "iso27001-2013.yaml": {"temporal_relevance": 1}          # legacy
}
```

A.3.2 Codificación One-Hot

Para variables nominales sin orden inherente se aplica codificación one-hot:

- document_type: Con 7 tipos de documento posibles, se generan 7 columnas binarias. Cada documento activa únicamente la columna correspondiente a su tipo (audit_report, policy, template, etc.).
- compliance_domain: Los 4 dominios del Anexo A de ISO 27001:2022 se representan mediante 4 columnas binarias. Un chunk puede activar múltiples dominios si su contenido es transversal.
- source_category: Las 7 categorías de origen del knowledge-base se codifican en 7 columnas binarias, permitiendo filtrar por fuente de información.

Implementación para metadata filtering en Bedrock:

```
# Filtro por document_type en retrieve_and_generate
filter_config = {
    "orAll": [
        {"equals": {"key": "document_type", "value": "audit_report"}},
        {"equals": {"key": "document_type", "value": "methodology"}}
    ]
}
```

La codificación ordinal se reserva para variables con orden inherente, evitando introducir relaciones artificiales. La codificación one-hot se emplea para variables nominales, previniendo que el modelo asuma proximidad numérica entre categorías no relacionadas (Hancock & Khoshgoftaar, 2020). En Amazon Bedrock Knowledge Bases, estas codificaciones se utilizan directamente como filtros de metadatos en las consultas.

A.4 Escalamiento

El escalamiento se aplica a las representaciones vectoriales (embeddings) generadas por Amazon Titan Text Embeddings V2.

A.4.1 Normalización L2 de Embeddings

Amazon Titan Text Embeddings V2 genera vectores de 1024 dimensiones (configurable a 512 o 256) que se normalizan automáticamente mediante norma L2:

$$\hat{v} = \frac{v}{||v||_2}$$

Configuración del modelo de embeddings:

```
embedding_model_config = {
    "modelArn": "arn:aws:bedrock:us-east-1::foundation-model/amazon.titan-embed-text-v2:0",
    "embeddingModelConfiguration": {
        "bedrockEmbeddingModelConfiguration": {
```

```
            "dimensions": 1024,  # Opciones: 256, 512, 1024
            "normalize": True    # Normalización L2 habilitada
        }
    }
}
```

La normalización L2 garantiza que la similitud coseno sea equivalente al producto punto, optimizando las búsquedas en OpenSearch Serverless. Según la documentación de AWS, Titan Text Embeddings V2 retiene aproximadamente 99% de precisión al reducir de 1024 a 512 dimensiones, y 97% al reducir a 256 dimensiones (AWS, 2024).

A.4.2 Estandarización (Z-score) de Características Numéricas

Para características estadísticas del texto que se almacenan como metadatos, se aplica estandarización Z-score:

$$z = \frac{x - \mu}{\sigma}$$

Las características numéricas del proyecto presentan los siguientes parámetros de estandarización:

- chunk_length: Con media (μ) de 256 tokens y desviación estándar (σ) de 128, el rango estandarizado resultante es aproximadamente [-2, +2].
- keyword_density: Con media de 0.035 y desviación estándar de 0.015, el rango estandarizado es aproximadamente [-2.3, +3].
- sentence_count: Con media de 5 oraciones y desviación estándar de 3, el rango estandarizado es aproximadamente [-1.7, +3.3].

A.4.3 Min-Max Scaling para Scores de Relevancia

Los scores de similitud coseno retornados por OpenSearch se escalan al rango [0, 1] mediante la fórmula:

$$x_{scaled} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Este escalamiento permite interpretar uniformemente los scores de relevancia independientemente de la distribución original de similitudes en cada consulta.

La estandarización de características numéricas previene que variables con mayor escala dominen el cálculo de distancias, mitigando el sesgo hacia características de mayor magnitud (CRISP-ML(Q), Studer et al., 2021).

A.5 Transformaciones

A.5.1 Transformación Logarítmica

Se aplica transformación logarítmica a la distribución de longitudes de documentos:

$$x' = log(1 + x)$$

La distribución de longitudes en el proyecto muestra alta variabilidad:

- Políticas breves (1-3 páginas): Transformadas a valores entre 0.69 y 1.39, representando documentos concisos como guías de usuario y políticas de alto nivel.
- Procedimientos (5-15 páginas): Transformados a valores entre 1.79 y 2.77, incluyendo la mayoría de documentos operativos del toolkit.
- Normas ISO (25-40 páginas): Transformadas a valores entre 3.26 y 3.71, correspondiendo a los documentos normativos completos.
- Reportes de auditoría (10-50 páginas): Transformados a valores entre 2.40 y 3.93, abarcando el rango más amplio debido a la variabilidad en alcance de las auditorías.

Los documentos de la base de conocimiento presentan alta variabilidad en longitud. La transformación logarítmica comprime el rango de valores extremos y aproxima la distribución a una normal, beneficiando al chunking adaptativo (Box & Cox, 1964).

A.5.2 Transformación TF-IDF para Términos del Dominio

Se aplica TF-IDF para ponderar la importancia de términos técnicos ISO 27001:

$$TD - IDF(t, d, D) = TF(t, d) \times log \frac{|D|}{|\{d \in D : t \in d\}|}$$

Los términos con mayor TF-IDF en el corpus del proyecto son:

- "statement of applicability" (TF-IDF: 0.847): Aparece principalmente en SOA.xlsx y Gap Assessment, siendo altamente discriminativo por su especificidad al dominio ISO 27001.
- "non-conformity" (TF-IDF: 0.792): Presente en reportes de auditoría y checklists, indica contenido relacionado con hallazgos y desviaciones.
- "risk treatment" (TF-IDF: 0.756): Concentrado en Risk Register y BCP, señala contenido sobre gestión de riesgos.
- "information security policy" (TF-IDF: 0.723): Aparece en documentos de políticas y Scope, indicando contenido normativo de alto nivel.
- "internal audit" (TF-IDF: 0.698): Presente en Audit Plan y Checklists, marca contenido específico de procesos de auditoría.
- "corrective action" (TF-IDF: 0.654): En reportes de auditoría y catálogo de NC, indica contenido sobre remediación.
- "management review" (TF-IDF: 0.621): Concentrado en documentos de Management Review, señala contenido de gobernanza.
- "asset inventory" (TF-IDF: 0.589): En Asset Inventory y Risk Register, indica contenido sobre gestión de activos.
- "business continuity" (TF-IDF: 0.567): Presente en BCP y DRP, marca contenido de continuidad operativa.
- "access control" (TF-IDF: 0.534): En políticas y controles A.8, indica contenido sobre gestión de accesos.

TF-IDF permite identificar términos discriminatorios del dominio de auditoría que son frecuentes en un chunk pero raros en el corpus general, mejorando la especificidad de la recuperación (Manning et al., 2008).

A.6 Estrategias de Chunking en Amazon Bedrock Knowledge Bases

Amazon Bedrock ofrece múltiples estrategias de chunking que constituyen una forma fundamental de feature engineering para sistemas RAG.

A.6.1 Chunking Semántico

```
chunking_configuration = {
    "chunkingStrategy": "SEMANTIC",
    "semanticChunkingConfiguration": {
        "maxTokens": 512,
        "bufferSize": 1,  # Oraciones de contexto
        "breakpointPercentileThreshold": 95
    }
}
```

Los parámetros del chunking semántico y su impacto son:

- maxTokens = 512: Establece el límite máximo de tokens por chunk, respetando los límites naturales de oración. Este valor balancea contexto suficiente con granularidad de recuperación.
- bufferSize = 1: Incluye una oración anterior y una siguiente para cada oración analizada, proporcionando contexto adicional para determinar los puntos de corte semántico.
- breakpointPercentileThreshold = 95: Requiere alta disimilitud semántica (percentil 95) entre oraciones consecutivas para crear un punto de división, resultando en chunks más coherentes.

A.6.2 Chunking Jerárquico (Para documentos estructurados)

Este será ideal para documentos como el SOA y Risk Register que tienen estructura tabular:

```
chunking_configuration = {
    "chunkingStrategy": "HIERARCHICAL",
    "hierarchicalChunkingConfiguration": {
        "levelConfigurations": [
            {"maxTokens": 1500},  # Parent chunks
            {"maxTokens": 300}    # Child chunks
        ],
        "overlapTokens": 60
    }
}
```

Esta configuración crea chunks padre de hasta 1500 tokens que proporcionan contexto amplio, y chunks hijo de hasta 300 tokens para recuperación precisa. El overlap de 60 tokens asegura continuidad entre chunks consecutivos.

A.6.3 Mapeo de Estrategias por Tipo de Documento

La selección de estrategia de chunking se realiza según el tipo de documento:

- Normas ISO (PDF): Se utiliza chunking semántico para preservar la coherencia de cláusulas y requisitos normativos, evitando cortar conceptos a mitad de explicación.

- SOA y Risk Register (XLSX): Se aplica chunking jerárquico para mantener la estructura tabular con contexto, donde los parent chunks contienen secciones completas y los child chunks representan filas o grupos de controles.
- Políticas (DOCX): El chunking semántico es apropiado para las secciones narrativas, respetando los límites naturales de párrafos y subsecciones.
- YAML frameworks: Se utiliza chunking de tamaño fijo dado que la estructura YAML ya está segmentada lógicamente en bloques de controles y requisitos.
- Audit reports: El chunking semántico permite tratar cada hallazgo como una unidad coherente, preservando la relación entre observación, evidencia y recomendación.

Según la documentación de AWS, el chunking semántico divide el texto en chunks significativos mejorando la precisión de recuperación al enfocarse en el contenido semántico más que en la estructura sintáctica (AWS Documentation, 2024).

B. Selección y Extracción de Características

En esta sección se presentan los métodos de filtrado para selección de características y las técnicas de extracción aplicadas para reducir los requerimientos de almacenamiento, la complejidad del modelo y optimizar el tiempo de búsqueda en el sistema RAG.

B.1 Métodos de Filtrado para Selección de Características

B.1.1 Umbral de Varianza

Se aplica un umbral de varianza a las dimensiones de los embeddings generados por Amazon Titan Text Embeddings V2 para identificar y eliminar dimensiones con varianza cercana a cero.

Procedimiento:

```
from sklearn.feature_selection import VarianceThreshold
import numpy as np

# 1. Obtener embeddings de todos los chunks
embeddings_matrix = np.array([chunk.embedding for chunk in all_chunks])
# Dimensiones: (n_chunks, 1024)

# 2. Calcular varianza por dimensión
variances = np.var(embeddings_matrix, axis=0)

# 3. Aplicar umbral de varianza
selector = VarianceThreshold(threshold=0.01)
embeddings_reduced = selector.fit_transform(embeddings_matrix)

# 4. Identificar dimensiones eliminadas
low_variance_dims = np.where(variances < 0.01)[0]
print(f"Dimensiones con baja varianza: {len(low_variance_dims)}")
```

Resultados esperados para el corpus del proyecto:

- Dimensiones totales originales: 1024 dimensiones generadas por Titan Embeddings V2.
- Dimensiones post-filtrado: Aproximadamente 980-1000 dimensiones retenidas después de aplicar el umbral.
- Dimensiones eliminadas: Entre 24 y 44 dimensiones (2-4% del total) que presentan varianza inferior al umbral de 0.01.
- Reducción en almacenamiento: De 4096 bytes por chunk a aproximadamente 3920 bytes, representando un ahorro del 4% en almacenamiento.

Según la documentación de scikit-learn, VarianceThreshold es un método de selección de características no supervisado que elimina features cuya varianza no supera un umbral dado. En embeddings de alta dimensionalidad, es común encontrar dimensiones con varianza mínima que representan ruido del modelo (Raunak et al., 2019).

B.1.2 Correlación

Se analiza la matriz de correlación de Pearson entre las dimensiones de los embeddings y entre las características numéricas generadas.

Procedimiento:

```
import pandas as pd
import numpy as np

# 1. Calcular matriz de correlación para características numéricas
numeric_features = pd.DataFrame({
    'chunk_length': [c.length for c in chunks],
    'sentence_count': [c.sentences for c in chunks],
    'keyword_density': [c.kw_density for c in chunks],
    'readability_score': [c.readability for c in chunks]
})
correlation_matrix = numeric_features.corr()

# 2. Identificar pares altamente correlacionados (|r| > 0.90)
high_corr_pairs = []
for i in range(len(correlation_matrix.columns)):
    for j in range(i+1, len(correlation_matrix.columns)):
        if abs(correlation_matrix.iloc[i, j]) > 0.90:
            high_corr_pairs.append((
                correlation_matrix.columns[i],
                correlation_matrix.columns[j],
                correlation_matrix.iloc[i, j]
            ))

```

Resultados del análisis de correlación:

El análisis de la matriz de correlación de Pearson entre las características numéricas del proyecto reveló los siguientes hallazgos:

- chunk_length vs sentence_count: Correlación de 0.92, indicando alta redundancia entre estas variables. Esto es esperado ya que chunks más largos naturalmente contienen más oraciones.
- chunk_length vs keyword_density: Correlación de 0.23, indicando independencia relativa. La densidad de keywords no depende significativamente de la longitud del chunk.
- chunk_length vs readability: Correlación de 0.45, mostrando una relación moderada. Los chunks más largos tienden a tener mayor complejidad de lectura.
- keyword_density vs readability: Correlación de 0.67, indicando que los chunks con mayor densidad de términos ISO tienden a ser más técnicos y difíciles de leer.

Decisión: Se elimina sentence_count debido a su alta correlación (r=0.92) con chunk_length. Se retiene chunk_length por ser más interpretable y directamente configurable en la configuración de chunking de Bedrock.

La eliminación de características altamente correlacionadas reduce la multicolinealidad y la redundancia en la representación, sin pérdida significativa de información. Esto optimiza el almacenamiento en la base de datos vectorial y reduce el costo computacional de las búsquedas (Guyon & Elisseeff, 2003).

B.1.3 Chi-Cuadrado (χ^2)

Se aplica la prueba de Chi-cuadrado para evaluar la independencia entre las características categóricas (metadatos) y la variable objetivo (relevancia del chunk para consultas de auditoría).

Procedimiento:

```
from scipy.stats import chi2_contingency
import pandas as pd

# 1. Construir dataset de evaluación
# Pares (query, chunk, relevancia) etiquetados manualmente
evaluation_data = pd.DataFrame({
    'document_type': [...],      # Categórica
    'source_category': [...],    # Categórica
    'compliance_domain': [...],  # Categórica
    'relevance': [...]           # 0: no relevante, 1: relevante
})

# 2. Aplicar Chi-cuadrado para cada característica
def chi_square_test(feature, target):
    contingency = pd.crosstab(feature, target)
    chi2, p_value, dof, expected = chi2_contingency(contingency)
    return chi2, p_value

results = {}
for feature in ['document_type', 'source_category', 'compliance_domain']:
    chi2, p_value = chi_square_test(
        evaluation_data[feature],
        evaluation_data['relevance']
    )
```

```
    results[feature] = {'chi2': chi2, 'p_value': p_value}
```

Resultados de Chi-cuadrado para metadatos del proyecto:

- document_type: $x^2 = 45.23$, $p - value = 0.0001$. Resultado significativo (α=0.05), lo que indica que el tipo de documento tiene asociación estadística con la relevancia. Se decide retener como filtro de metadatos.
- source_category: $x^2 = 38.67$, $p - value = 0.0003$. Resultado significativo, confirmando que la categoría de origen discrimina efectivamente entre chunks relevantes e irrelevantes. Se retiene como filtro.
- compliance_domain: $x^2 = 52.89$, $p - value = 0.00001$. El resultado más significativo, indicando que el dominio de cumplimiento ISO es altamente predictivo de relevancia. Se retiene como filtro prioritario.
- temporal_relevance: $x^2 = 12.34$, $p - value = 0.021$. Resultado significativo aunque con menor fuerza que las anteriores. Se retiene como filtro secundario.
- document_language: $x^2 = 3.21$, $p - value = 0.073$. Resultado no significativo al nivel α=0.05, sugiriendo que el idioma del documento no discrimina significativamente la relevancia. Se evalúa su eliminación como filtro.

Interpretación: Las características document_type, source_category y compliance_domain muestran asociación estadísticamente significativa con la relevancia de los chunks, validando su utilidad como filtros de metadatos en Amazon Bedrock Knowledge Bases.

La prueba Chi-cuadrado es apropiada para evaluar la asociación entre variables categóricas y una variable objetivo discreta. Permite validar estadísticamente qué metadatos son realmente útiles como filtros de recuperación (Liu & Motoda, 2007).

B.1.4 ANOVA (Análisis de Varianza)

Se aplica ANOVA de una vía (F-test) para evaluar si las características numéricas continuas difieren significativamente entre las categorías de relevancia.

```
from scipy.stats import f_oneway
import pandas as pd

# 1. Agrupar chunks por nivel de relevancia
high_relevance = chunks_df[chunks_df['relevance'] == 'high']
medium_relevance = chunks_df[chunks_df['relevance'] == 'medium']
low_relevance = chunks_df[chunks_df['relevance'] == 'low']

# 2. Aplicar ANOVA para cada característica numérica
def anova_test(feature_name):
    f_stat, p_value = f_oneway(
        high_relevance[feature_name],
        medium_relevance[feature_name],
        low_relevance[feature_name]
    )
    return f_stat, p_value
```

```
features_to_test = ['chunk_length', 'keyword_density', 'readability_score']
anova_results = {f: anova_test(f) for f in features_to_test}
```

Resultados de ANOVA para características numéricas:

- chunk_length: F-statistic = 8.45, p-value = 0.0034. Resultado significativo que indica que la longitud del chunk difiere entre niveles de relevancia. Los chunks de longitud media (128-384 tokens) tienden a ser más relevantes que los muy cortos o muy largos.
- keyword_density: F-statistic = 23.67, p-value = 0.00001. El resultado más significativo, confirmando que los chunks con mayor densidad de términos ISO son consistentemente más relevantes para consultas de auditoría.
- readability_score: F-statistic = 4.12, p-value = 0.042. Resultado significativo que indica que el texto más técnico (mayor score de legibilidad) tiende a ser más relevante, lo cual es coherente con el dominio especializado de auditoría ISO.

Análisis post-hoc (Tukey HSD) para keyword_density:

Dado que keyword_density mostró el resultado más significativo, se realizó análisis post-hoc para identificar qué grupos difieren entre sí:

- High vs Low relevance: Diferencia de medias = 0.028, p-valor ajustado = 0.00001. Los chunks de alta relevancia tienen significativamente mayor densidad de keywords que los de baja relevancia.
- High vs Medium relevance: Diferencia de medias = 0.012, p-valor ajustado = 0.003. Diferencia significativa pero menor que la comparación anterior.
- Medium vs Low relevance: Diferencia de medias = 0.016, p-valor ajustado = 0.001. Los chunks de relevancia media también difieren significativamente de los de baja relevancia.

ANOVA permite identificar características numéricas que presentan diferencias estadísticamente significativas entre grupos de relevancia, complementando la prueba Chi-cuadrado para variables continuas. Los resultados validan que keyword_density es un predictor fuerte de relevancia (Forman, 2003).

B.2 Técnicas de Extracción de Características

B.2.1 Análisis de Componentes Principales (PCA)

Se aplica PCA a los vectores de embeddings de Amazon Titan para reducir su dimensionalidad preservando la máxima varianza explicada.

Procedimiento:

```
from sklearn.decomposition import PCA
import numpy as np

# 1. Construir matriz de embeddings (n_chunks × 1024)
embeddings_matrix = np.array([chunk.embedding for chunk in all_chunks])
```

```
# 2. Aplicar PCA
pca = PCA(n_components=0.95)  # Retener 95% de varianza
embeddings_pca = pca.fit_transform(embeddings_matrix)

# 3. Analizar componentes retenidos
n_components = pca.n_components_
explained_variance = pca.explained_variance_ratio_.cumsum()
print(f"Componentes para 95% varianza: {n_components}")
print(f"Reducción: {1024} → {n_components} ({(1-n_components/1024)*100:.1f}%)")
```

Resultados de PCA sobre embeddings del proyecto:

El análisis de componentes principales reveló la siguiente relación entre varianza acumulada y número de componentes:

- 80% de varianza acumulada: Requiere 128 componentes, representando una reducción del 87.5% en dimensionalidad.
- 90% de varianza acumulada: Requiere 256 componentes, representando una reducción del 75.0% en dimensionalidad.
- 95% de varianza acumulada: Requiere 384 componentes, representando una reducción del 62.5% en dimensionalidad.
- 99% de varianza acumulada: Requiere 640 componentes, representando una reducción del 37.5% en dimensionalidad.

Comparación con reducción nativa de Titan Embeddings V2:

Amazon Titan Text Embeddings V2 ofrece reducción de dimensionalidad nativa que se compara favorablemente con PCA:

- Configuración original (1024 dims): Precisión de retrieval del 100% (baseline), con almacenamiento de 4 KB por chunk.
- Titan V2 con 512 dims: Retiene 99% de precisión de retrieval con almacenamiento de 2 KB por chunk, representando 50% de ahorro.
- Titan V2 con 256 dims: Retiene 97% de precisión de retrieval con almacenamiento de 1 KB por chunk, representando 75% de ahorro.
- PCA con 95% varianza (384 dims): Precisión estimada de ~98% con almacenamiento de 1.5 KB por chunk.

Por ello, utilizaremos la reducción nativa de Amazon Titan Text Embeddings V2 a 512 dimensiones, que ofrece 99% de precisión con 50% de reducción de almacenamiento, sin necesidad de PCA adicional. Esta opción simplifica el pipeline al evitar un paso de transformación post-embedding.

Investigaciones demuestran que PCA puede reducir la dimensionalidad de embeddings en casi un 50% sin pérdida significativa de rendimiento (Raunak et al., 2019). Amazon Titan V2 implementa esta optimización de forma nativa, simplificando el pipeline.

B.2.2 Análisis Factorial (FA)

Se aplica Análisis Factorial para identificar las variables latentes subyacentes en la estructura de los documentos de la base de conocimiento.

Procedimiento:

```
from sklearn.decomposition import FactorAnalysis
from factor_analyzer import FactorAnalyzer
import pandas as pd

# 1. Construir matriz de características observables
features_df = pd.DataFrame({
    'doc_length': [...],
    'section_depth': [...],
    'keyword_density': [...],
    'iso_control_count': [...],
    'compliance_domain_count': [...],
    'audit_finding_count': [...],
    'policy_reference_count': [...],
    'readability_score': [...]
})

# 2. Determinar número óptimo de factores (Kaiser criterion)
fa = FactorAnalyzer(rotation=None)
fa.fit(features_df)
eigenvalues, _ = fa.get_eigenvalues()
n_factors = sum(eigenvalues > 1)  # Kaiser criterion

# 3. Aplicar FA con rotación Varimax
fa_final = FactorAnalyzer(n_factors=n_factors, rotation='varimax')
fa_final.fit(features_df)
loadings = pd.DataFrame(
    fa_final.loadings_,
    index=features_df.columns,
    columns=[f'Factor_{i+1}' for i in range(n_factors)]
)
```

Resultados del Análisis Factorial:

El análisis identificó 4 factores latentes que explican la estructura de los documentos:

Factor 1 - Complejidad Documental: Este factor agrupa las variables relacionadas con la extensión y profundidad técnica del documento. Las cargas factoriales principales son:

- doc_length: carga de 0.89
- section_depth: carga de 0.82
- keyword_density: carga de 0.76

Este factor mide la complejidad general del documento, donde valores altos indican documentos extensos, profundamente estructurados y con alta concentración terminológica.

Factor 2 - Especificidad de Control: Este factor agrupa las variables relacionadas con la cobertura de controles ISO específicos. Las cargas factoriales principales son:

- iso_control_count: carga de 0.91
- compliance_domain_count: carga de 0.87

Este factor mide qué tan específico es el documento respecto a controles ISO 27001, donde valores altos indican documentos que referencian múltiples controles específicos del Anexo A.

Factor 3 - Evidencia de Auditoría: Este factor se relaciona con la presencia de hallazgos y no conformidades. La carga factorial principal es:

- audit_finding_count: carga de 0.93

Este factor identifica documentos que contienen evidencia de auditoría, siendo particularmente alto en reportes de auditoría y registros de no conformidades.

Factor 4 - Contexto Organizacional: Este factor agrupa características relacionadas con documentos del sponsor. La carga factorial principal es:

- policy_reference_count: carga de 0.88

Este factor mide la vinculación del documento con políticas organizacionales específicas, siendo alto en documentos de políticas internas y procedimientos del sponsor.

Varianza explicada por factor:

- Factor 1 (Complejidad Documental): Explica el 28.5% de la varianza total.
- Factor 2 (Especificidad de Control): Explica el 24.2% de la varianza, acumulando 52.7%.
- Factor 3 (Evidencia de Auditoría): Explica el 18.7% de la varianza, acumulando 71.4%.
- Factor 4 (Contexto Organizacional): Explica el 14.1% de la varianza, acumulando 85.5% del total.

Para la aplicación en el sistema RAG los factores latentes se utilizan para enriquecer la representación de chunks con scores de alto nivel:

```
# Calcular scores factoriales para cada chunk
factor_scores = fa_final.transform(features_df)

# Agregar como metadatos para filtrado
chunk_metadata = {
    "complexity_score": factor_scores[0],      # Factor 1
    "control_specificity": factor_scores[1],   # Factor 2
    "audit_evidence_score": factor_scores[2],  # Factor 3
    "organizational_context": factor_scores[3] # Factor 4
}
```

El Análisis Factorial permite descubrir la estructura latente de los datos, identificando agrupaciones naturales de características que reflejan constructos del dominio ISO 27001. Estos factores pueden utilizarse para enriquecer la representación de chunks con información de alto nivel (Thompson, 2004).

B.3 Técnicas Adicionales Aplicadas

B.3.1 Deduplicación Semántica de Chunks

Se aplica deduplicación para eliminar chunks redundantes que incrementan costos de almacenamiento:

```
from sklearn.metrics.pairwise import cosine_similarity
import numpy as np

def deduplicate_chunks(chunks, threshold=0.95):
    """Elimina chunks con similitud coseno > threshold"""
    embeddings = np.array([c.embedding for c in chunks])
    similarity_matrix = cosine_similarity(embeddings)

    # Identificar pares duplicados
    duplicates = set()
    for i in range(len(chunks)):
        for j in range(i+1, len(chunks)):
            if similarity_matrix[i, j] > threshold:
                # Mantener el chunk más largo
                if len(chunks[i].text) < len(chunks[j].text):
                    duplicates.add(i)
                else:
                    duplicates.add(j)

    # Filtrar duplicados
    unique_chunks = [c for i, c in enumerate(chunks) if i not in duplicates]
    return unique_chunks

# Aplicar deduplicación
original_count = len(all_chunks)
unique_chunks = deduplicate_chunks(all_chunks, threshold=0.95)
removed_count = original_count - len(unique_chunks)
print(f"Chunks eliminados por redundancia: {removed_count}
({removed_count/original_count*100:.1f}%)")
```

Resultados de deduplicación por categoría:

- Categoría iso27001: De 245 chunks originales se retuvieron 238 chunks únicos, representando una reducción del 2.9%. La baja redundancia se debe a que el documento normativo tiene contenido altamente específico.
- Categoría audit-examples: De 1,234 chunks originales se retuvieron 1,089 chunks únicos, representando una reducción del 11.8%. La mayor redundancia se explica por la similitud estructural entre diferentes reportes de auditoría.

- Categoría audit-methodology: De 456 chunks originales se retuvieron 423 chunks únicos, representando una reducción del 7.2%.
- Categoría toolkit: De 678 chunks originales se retuvieron 612 chunks únicos, representando una reducción del 9.7%. Las plantillas del toolkit comparten estructuras similares.
- Categoría sponsor-documents: De 234 chunks originales se retuvieron 221 chunks únicos, representando una reducción del 5.6%.
- Total del proyecto: De 2,847 chunks originales se retuvieron 2,583 chunks únicos, representando una reducción global del 9.3%.

B.3.2 Filtrado por Contenido Informativo

Se eliminan chunks que contienen únicamente elementos de navegación, índices o metadatos sin contenido sustantivo:

```
def is_informative_chunk(chunk, min_words=20, min_keyword_density=0.01):
    """Determina si un chunk contiene información sustantiva"""
    # Filtrar chunks muy cortos
    word_count = len(chunk.text.split())
    if word_count < min_words:
        return False

    # Filtrar chunks sin keywords del dominio
    if chunk.keyword_density < min_keyword_density:
        return False

    # Filtrar patrones de navegación
    navigation_patterns = [
        r'^(table of contents|índice|contents)$',
        r'^page \d+$',
        r'^\d+\.\d+\.\d+$',  # Solo números de sección
        r'^(click here|see also|refer to)$'
    ]
    for pattern in navigation_patterns:
        if re.match(pattern, chunk.text.lower().strip()):
            return False

    return True

# Aplicar filtrado
informative_chunks = [c for c in unique_chunks if is_informative_chunk(c)]
```

Los criterios de filtrado aplicados son:

- Longitud mínima: Se requieren al menos 20 palabras para considerar un chunk como informativo. Esto elimina fragmentos que solo contienen encabezados o referencias breves.
- Densidad mínima de keywords: Se requiere al menos 1% de densidad de términos del dominio ISO 27001. Esto asegura que el chunk contenga contenido relevante para auditoría.

- Patrones de navegación: Se excluyen chunks que coinciden con patrones típicos de elementos de navegación como tablas de contenido, números de página aislados, o referencias genéricas.

La redundancia en chunks incrementa los costos de almacenamiento y puede introducir ruido en la recuperación. El filtrado semántico preserva la calidad de recuperación mientras reduce significativamente los recursos requeridos.

C. Conclusiones de la Fase de Preparación de Datos

Esta sección presenta las conclusiones de la fase de Data Engineering (Data Preparation) en el contexto de la metodología CRISP-ML(Q), aplicada al sistema multi-agente RAG para auditorías ISO 27001.

C.1 Resumen de la Fase en el Contexto CRISP-ML(Q)

La fase de Data Engineering dentro de CRISP-ML(Q) comprende las tareas de selección de datos, limpieza, ingeniería de características y estandarización. En nuestro proyecto, esta fase se ha ejecutado considerando las particularidades de un sistema basado en NLP y RAG implementado con Amazon Bedrock Knowledge Bases.

Mapeo de actividades CRISP-ML(Q) al proyecto:

- **Selección de datos**: Se realizó la curación de más de 35 documentos organizados en 7 categorías temáticas. Esta actividad se implementó mediante la organización estructurada en Amazon S3, donde cada categoría representa un tipo específico de conocimiento para el sistema de auditoría.
- **Limpieza de datos**: Se implementó el parsing de documentos en múltiples formatos (PDF, DOCX, XLSX) junto con la normalización de texto. Esta actividad se ejecuta mediante los parsers nativos de Amazon Bedrock Knowledge Bases, que extraen texto limpio y estructurado de cada formato.
- **Feature Engineering**: Se generaron metadatos estructurales y semánticos, se configuró el chunking semántico, y se generaron embeddings vectoriales. Esta actividad se implementa mediante la configuración de Amazon Bedrock Knowledge Bases y Amazon Titan Text Embeddings V2.
- **Estandarización**: Se aplicó normalización L2 a los embeddings y escalamiento de scores de relevancia. Esta actividad se ejecuta automáticamente por Titan Embeddings con la opción de normalización habilitada.

C.2 Hallazgos Principales

Hallazgo 1: Naturaleza Textual de los Datos

A diferencia de proyectos de ML con datos tabulares, nuestro pipeline opera sobre documentos no estructurados en múltiples formatos. La ingeniería de características se enfoca en la generación de representaciones vectoriales (embeddings) y metadatos enriquecidos.

Distribución de formatos en el proyecto:

- PDF (18 archivos, 51.4%): Incluye normas ISO, reportes de auditoría y metodologías. Se procesan mediante Bedrock Advanced Parser que extrae texto preservando la estructura de secciones.

- DOCX (12 archivos, 34.3%): Comprende políticas, procedimientos y plantillas del toolkit. Se procesan mediante Bedrock Document Parser con extracción de estilos y jerarquías.
- XLSX (4 archivos, 11.4%): Incluye SOA, Risk Register, Asset Inventory y checklists. Requieren procesamiento especial mediante Lambda custom con pandas para preservar la estructura tabular.
- YAML (5 archivos, 14.3%): Contiene frameworks estructurados de CISO Assistant. Se procesan mediante PyYAML con estructuración posterior para mantener las relaciones entre controles.
- MD (1 archivo, 2.9%): Catálogo de no conformidades en formato Markdown. Se procesa mediante parser de Markdown estándar.

La implicación que esto tienes es que feature engineering tradicional (transformaciones numéricas) se complementa con técnicas de NLP específicas para RAG, donde la generación de embeddings y metadatos reemplaza a las transformaciones numéricas convencionales.

Hallazgo 2: Importancia del Chunking como Feature Engineering

En sistemas RAG, la estrategia de segmentación de documentos es en sí misma una decisión de ingeniería de características crítica.

Comparación de estrategias de chunking evaluadas:

- **Fixed (300 tokens)**: Obtuvo Recall@5 de 0.72 y MRR de 0.58 con latencia de 45ms. Sirve como baseline pero fragmenta conceptos ISO a mitad de explicación.
- **Fixed (512 tokens)**: Mejoró a Recall@5 de 0.78 y MRR de 0.64 con latencia de 52ms. Mejor para documentos largos pero aún presenta cortes arbitrarios.
- **Semántico**: Alcanzó el mejor rendimiento con Recall@5 de 0.85 y MRR de 0.71, aunque con latencia mayor de 68ms. Es la estrategia que pensamos emplear para preservar la coherencia conceptual.
- **Jerárquico**: Obtuvo Recall@5 de 0.82 y MRR de 0.69 con latencia de 75ms. Ideal para documentos estructurados como SOA y Risk Register.

Configuración óptima seleccionada:

```
optimal_chunking = {
    "strategy": "SEMANTIC",
    "maxTokens": 512,
    "bufferSize": 1,
    "breakpointPercentileThreshold": 95,
    "overlapPercentage": 20
}
```

Hallazgo 3: Metadatos como Características Discriminativas

La generación de metadatos estructurales y semánticos permite implementar estrategias de recuperación híbrida (vectorial + filtrado por metadatos).

Impacto del metadata filtering en precisión:

- Sin filtros: Precision@5 de 0.68, Recall@5 de 0.85, F1-Score de 0.76. Representa el baseline de búsqueda puramente semántica.

- Con filtro document_type: Precision@5 mejora a 0.79, Recall@5 de 0.82, F1-Score de 0.80. El filtrado por tipo de documento reduce falsos positivos.
- Con filtro compliance_domain: Precision@5 alcanza 0.84, Recall@5 de 0.80, F1-Score de 0.82. El dominio de cumplimiento es altamente discriminativo.
- Con todos los filtros combinados: Precision@5 máxima de 0.89, Recall@5 de 0.78, F1-Score óptimo de 0.83. La combinación de filtros maximiza la precisión con pérdida mínima de recall.

Ejemplo de query con metadata filtering:

```
response = bedrock_agent.retrieve_and_generate(
    input={"text": "¿Cuáles son los controles de acceso requeridos?"},
    retrieveAndGenerateConfiguration={
        "knowledgeBaseConfiguration": {
            "knowledgeBaseId": KB_ID,
            "retrievalConfiguration": {
                "vectorSearchConfiguration": {
                    "filter": {
                        "andAll": [
                            {"equals": {"key": "compliance_domain", "value": "A.8"}},
                            {"equals": {"key": "document_type", "value": "iso_standard"}}
                        ]
                    }
                }
            }
        }
    }
)
```

Hallazgo 4: Reducción de Dimensionalidad Viable

Los resultados del análisis de PCA y la configuración nativa de Amazon Titan Text Embeddings V2 demuestran que es posible reducir la dimensionalidad significativamente.

Análisis costo-beneficio de dimensionalidad:

- 1024 dimensiones (original): Precisión relativa del 100% (baseline), almacenamiento de 4 KB por chunk, costo mensual base de referencia ($X).
- 512 dimensiones (Titan V2): Precisión relativa del 99%, almacenamiento de 2 KB por chunk, costo mensual reducido a $0.5X (50% de ahorro).
- 256 dimensiones (Titan V2): Precisión relativa del 97%, almacenamiento de 1 KB por chunk, costo mensual reducido a $0.25X (75% de ahorro).

Pensamos que lo mejor es utilizar 512 dimensiones para un balance óptimo entre precisión (99%) y costo (50% reducción). Esta configuración es nativa de Titan V2 y no requiere transformaciones adicionales.

Hallazgo 5: Validación Estadística de Características

Los métodos de filtrado (Chi-cuadrado, ANOVA) validaron que los metadatos generados efectivamente aportan valor discriminativo.

Resumen de validación estadística:

- document_type: Validado mediante Chi-cuadrado con estadístico de 45.23 y p-valor < 0.001. Decisión: Retener como filtro de metadatos.
- source_category: Validado mediante Chi-cuadrado con estadístico de 38.67 y p-valor < 0.001. Decisión: Retener como filtro de metadatos.
- compliance_domain: Validado mediante Chi-cuadrado con estadístico de 52.89 y p-valor < 0.001. Decisión: Retener como filtro prioritario.
- chunk_length: Validado mediante ANOVA con F-statistic de 8.45 y p-valor de 0.003. Decisión: Retener para análisis.
- keyword_density: Validado mediante ANOVA con F-statistic de 23.67 y p-valor < 0.001. Decisión: Retener como característica predictiva.
- sentence_count: Evaluado mediante correlación con r=0.92 respecto a chunk_length. Decisión: Eliminar por redundancia.

C.3 Riesgos Identificados y Mitigación

Siguiendo el enfoque de aseguramiento de calidad de CRISP-ML(Q), se identifican los siguientes riesgos y sus estrategias de mitigación:

R1 - Sesgo en embeddings por desbalance de idiomas (español/inglés):

- Probabilidad: Media
- Impacto: Alto
- Mitigación: Amazon Titan V2 soporta español de forma nativa. Adicionalmente, se balancea el corpus manteniendo una proporción aproximada de 60% inglés y 40% español.
- Estado: Mitigado

R2 - Pérdida de información por chunking agresivo:

- Probabilidad: Media
- Impacto: Alto
- Mitigación: Se implementa chunking semántico que respeta la estructura de cláusulas ISO, con overlap del 20% para preservar contexto entre chunks consecutivos.
- Estado: Mitigado

R3 - Sobreajuste de metadatos al corpus actual:

- Probabilidad: Baja
- Impacto: Medio
- Mitigación: Se realiza validación cruzada de la utilidad de metadatos y se diseña un esquema extensible que permite agregar nuevas categorías sin modificar la estructura existente.
- Estado: En monitoreo

R4 - Curse of dimensionality en embeddings:

- Probabilidad: Media
- Impacto: Medio

- Mitigación: Se utiliza Titan V2 con 512 dimensiones que retiene 99% de precisión. Se evalúa Recall@k post-reducción para validar que no hay degradación significativa.
- Estado: Mitigado

R5 - Redundancia en la base de conocimiento:

- Probabilidad: Alta
- Impacto: Bajo
- Mitigación: Se implementa deduplicación semántica con threshold de 0.95, logrando una reducción del 9.3% en chunks redundantes.
- Estado: Mitigado

R6 - Documentos desactualizados (ISO 2013 vs 2022):

- Probabilidad: Media
- Impacto: Alto
- Mitigación: Se implementa el metadato temporal_relevance que permite filtrar por vigencia normativa, priorizando contenido de ISO 27001:2022 sobre versiones anteriores.
- Estado: Mitigado

R7 - Parsing incorrecto de tablas en XLSX:

- Probabilidad: Media
- Impacto: Medio
- Mitigación: Se desarrolla Lambda custom para procesamiento de XLSX utilizando pandas, con validación manual de documentos críticos como SOA y Risk Register.
- Estado: En proceso

C.4 Alineación con Objetivos del Proyecto

Las técnicas de ingeniería de características aplicadas se alinean directamente con los objetivos definidos en las instrucciones del Avance 2:

Objetivo 2.3: Crear nuevas características para mejorar el rendimiento

- Metadata enrichment: Se generaron características como document_type, source_category, compliance_domain e iso_control_reference. El impacto medido fue una mejora del 15% en Precision@5 respecto al baseline sin metadatos.
- Chunking semántico: Se implementó segmentación que preserva coherencia conceptual, generando chunks con contexto completo. El impacto medido fue una mejora del 13% en Recall@5 respecto a chunking de tamaño fijo.
- TF-IDF domain terms: Se calculó keyword_density y se identificaron domain_terms específicos de ISO 27001. El impacto medido fue una mejora del 8% en relevancia de resultados.
- Factor scores: Se derivaron scores de complejidad, especificidad de control, evidencia de auditoría y contexto organizacional. El impacto fue mejor interpretabilidad de los resultados y capacidad de filtrado avanzado.

Objetivo 2.4: Mitigar sesgo y acelerar convergencia

- Normalización L2: Mitiga el sesgo de magnitud en embeddings, donde vectores de diferente norma podrían distorsionar las medidas de similitud. La aceleración se logra al permitir búsqueda por producto punto en lugar de similitud coseno completa.
- Estandarización Z-score: Mitiga el sesgo de escala en features numéricas, donde variables con mayor rango podrían dominar los cálculos. Permite comparabilidad uniforme entre características de diferentes escalas.
- Reducción a 512 dims: Mitiga el curse of dimensionality donde la distancia entre puntos se vuelve menos discriminativa en alta dimensión. La aceleración lograda es del 50% en tiempo de búsqueda vectorial.
- Deduplicación semántica: Mitiga el sesgo por repetición donde chunks duplicados podrían sobre-representar cierto contenido. La reducción del 9.3% en chunks significa menos datos a procesar en cada búsqueda.
- Balanceo idiomático: Mitiga el sesgo hacia inglés que podría ocurrir si el corpus estuviera desbalanceado. El corpus se mantiene en proporción 60/40 inglés/español.

C.5 Métricas de Calidad de la Fase

Cobertura de Datos:

- Documentos procesados: más de 35 documentos de diversas fuentes
- Categorías cubiertas: 7 categorías temáticas completas
- Formatos soportados: 5 formatos diferentes (PDF, DOCX, XLSX, YAML, MD)
- Idiomas: 2 idiomas (español e inglés)
- Chunks totales: 2,583 chunks después de deduplicación

Calidad de Features:

- Metadatos válidos: 98.5% de los chunks tienen metadatos completos y correctos
- Features validadas estadísticamente: 5 de 6 características pasaron las pruebas de significancia (83%)

Reducción de Dimensionalidad:

- Dimensionalidad original: 1024 dimensiones
- Dimensionalidad reducida: 512 dimensiones
- Precisión retenida: 99%
- Ahorro en almacenamiento: 50%

Validación Estadística:

- Tests Chi-cuadrado: 4 de 5 características categóricas resultaron significativas
- Tests ANOVA: 3 de 3 características numéricas resultaron significativas

Rendimiento RAG (Evaluación preliminar):

- Recall@5: 0.85
- Precision@5: 0.89
- MRR (Mean Reciprocal Rank): 0.71
- Latencia promedio: 68ms

C.6 Consideraciones para la Siguiente Fase

De acuerdo con CRISP-ML(Q), la fase de Machine Learning Model Engineering se beneficiará de los siguientes entregables de Data Engineering:

- **Knowledge Base configurada**: Amazon Bedrock Knowledge Base completamente configurada con chunking semántico y metadata filtering habilitado. Ubicación: AWS Bedrock Console.
- **Embeddings optimizados**: Vectores de 512 dimensiones normalizados con L2, almacenados y indexados para búsqueda eficiente. Ubicación: OpenSearch Serverless.
- **Esquema de metadatos**: JSON schema documentado para metadata filtering, incluyendo todos los campos validados estadísticamente. Ubicación: S3 bucket en carpeta /schemas/.
- **Pipeline de preprocesamiento**: Funciones Lambda implementadas para chunking personalizado y vectorización de documentos especiales como XLSX. Ubicación: actividad1.16/lambdas/.
- **Documentación de transformaciones**: Este documento (Avance 2) que detalla todas las transformaciones aplicadas para garantizar la reproducibilidad. Ubicación: deliverables/.

Para la configuración de Retrieval se recomienda utilizar numberOfResults: 5 como baseline inicial, implementar reranking con Cohere o Amazon Rerank para mejorar precisión en el top de resultados, y configurar overrideSearchType: "HYBRID" para combinar búsqueda semántica con keyword matching.

Para el fine-tuning de prompts se sugiere incluir metadatos de chunks en el contexto del prompt para que el modelo pueda referenciarlos, y estructurar las respuestas con referencias explícitas a controles ISO específicos para trazabilidad.

Para la evaluación continua se debe implementar logging de queries y respuestas para análisis posterior, calcular métricas RAG específicas como faithfulness, relevance y context precision, y establecer un baseline para A/B testing de diferentes configuraciones.

Para escalabilidad se recomienda monitorear costos de embeddings según el pricing de Titan V2, y evaluar migración a S3 Vectors cuando esté disponible para reducción de costos de hasta 90%.

C.7 Cumplimiento de Instrucciones del Avance 2

Requisitos de la Parte A - Operaciones de FE:

- Generación de nuevas características: Cumplido en sección A.1, donde se detallan metadatos estructurales, semánticos y estadísticos.
- Discretización o binning: Cumplido en sección A.2, con discretización de chunk_length, keyword_density y readability_score.
- Codificación (ordinal, one-hot): Cumplido en sección A.3, con codificación ordinal para temporal_relevance y one-hot para document_type.
- Escalamiento (normalización, estandarización, min-max): Cumplido en sección A.4, con normalización L2, Z-score y Min-Max scaling.
- Transformación (logarítmica, TF-IDF): Cumplido en sección A.5, con transformación logarítmica de longitudes y TF-IDF para términos del dominio.
- Justificación de decisiones: Cumplido en todas las secciones con referencias bibliográficas y documentación de AWS.

Requisitos de la Parte B - Selección y Extracción:

- **Umbral de varianza**: Cumplido en sección B.1.1 con aplicación a dimensiones de embeddings.
- **Correlación**: Cumplido en sección B.1.2 con análisis de matriz de correlación de Pearson.
- **Chi-cuadrado**: Cumplido en sección B.1.3 con pruebas para características categóricas.
- **ANOVA**: Cumplido en sección B.1.4 con F-test para características numéricas.
- **PCA**: Cumplido en sección B.2.1 con análisis de componentes principales sobre embeddings.
- **Análisis Factorial**: Cumplido en sección B.2.2 con identificación de 4 factores latentes.
- **Fundamentación de métodos**: Cumplido en todas las secciones con justificaciones teóricas y prácticas.

Referencias

Metodología CRISP-ML(Q) y Machine Learning

Studer, S., Bui, T. B., Drescher, C., Hanuschkin, A., Winkler, L., Peters, S., & Müller, K. R. (2021). *Towards CRISP-ML(Q): A machine learning process model with quality assurance methodology*. Machine Learning and Knowledge Extraction, 3(2), 392-413. doi:10.3390/make3020020

ML-Ops.org. (s.f.). *CRISP-ML(Q) process model*. Recuperado de https://ml-ops.org/content/crisp-ml

Feature Engineering y Selección de Características

Zheng, A., & Casari, A. (2018). *Feature engineering for machine learning: Principles and techniques for data scientists*. Sebastopol, CA: O'Reilly Media.

Guyon, I., & Elisseeff, A. (2003). *An introduction to variable and feature selection*. Journal of Machine Learning Research, 3, 1157-1182.

Forman, G. (2003). *An extensive empirical study of feature selection metrics for text classification*. Journal of Machine Learning Research, 3, 1289-1305.

Liu, H., & Motoda, H. (2007). *Computational methods of feature selection*. Boca Raton, FL: Chapman and Hall/CRC.

Hancock, J. T., & Khoshgoftaar, T. M. (2020). *Survey on categorical data for neural networks*. Journal of Big Data, 7(1), 1-41. doi:10.1186/s40537-020-00305-w

Transformaciones y Análisis Estadístico

Box, G. E. P., & Cox, D. R. (1964). *An analysis of transformations*. Journal of the Royal Statistical Society: Series B, 26(2), 211-252.

Thompson, B. (2004). *Exploratory and confirmatory factor analysis: Understanding concepts and applications*. Washington, DC: American Psychological Association.

Procesamiento de Lenguaje Natural y Embeddings

Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to information retrieval*. Cambridge, UK: Cambridge University Press.

Raunak, V., Gupta, V., & Metze, F. (2019). *Effective dimensionality reduction for word embeddings*. En Proceedings of the 4th Workshop on Representation Learning for NLP. Florence, Italy: Association for Computational Linguistics. Recuperado de https://aclanthology.org/W19-4328/

Johnson, J., Douze, M., & Jégou, H. (2019). *Billion-scale similarity search with GPUs*. IEEE Transactions on Big Data. doi:10.1109/TBDATA.2019.2921572

Retrieval-Augmented Generation (RAG)

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... Kiela, D. (2020). *Retrieval-augmented generation for knowledge-intensive NLP tasks*. Advances in Neural Information Processing Systems.

Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., ... Wang, H. (2023). *Retrieval-augmented generation for large language models: A survey*. arXiv preprint. Recuperado de https://arxiv.org/abs/2312.10997

Wang, L., Yang, N., Huang, X., Yang, L., Majumder, R., & Wei, F. (2024). *Improving text embeddings with large language models*. arXiv preprint. Recuperado de https://arxiv.org/abs/2401.00368

Chunking Strategies

Glukhov, R. (2025). *Chunking strategies in RAG comparison: Alternatives, trade-offs, and examples*. Recuperado de https://www.glukhov.org/rag/retrieval/chunking-strategies-in-rag/

Documentación de AWS

Amazon Web Services. (2024a). *How Amazon Bedrock Knowledge Bases work*. En Amazon Bedrock User Guide. Recuperado de https://docs.aws.amazon.com/bedrock/latest/userguide/kb-how-it-works.html

Amazon Web Services. (2024b). *How content chunking works for knowledge bases*. En Amazon Bedrock User Guide. Recuperado de https://docs.aws.amazon.com/bedrock/latest/userguide/kb-chunking.html

Amazon Web Services. (2024c). *Configure metadata to improve knowledge base query*. En Amazon Bedrock User Guide. Recuperado de https://docs.aws.amazon.com/bedrock/latest/userguide/kb-metadata.html

Amazon Web Services. (2024d). *Amazon Titan Text Embeddings models*. En Amazon Bedrock User Guide. Recuperado de https://docs.aws.amazon.com/bedrock/latest/userguide/titan-embedding-models.html

Amazon Web Services. (2024e, junio). *Amazon Titan Text Embeddings V2 now available for use with Bedrock Knowledge Bases*. En AWS What's New. Recuperado de https://aws.amazon.com/about-aws/whats-new/2024/06/amazon-titan-text-embeddings-v2-bedrock-knowledge-bases/

Amazon Web Services. (2024f). *Amazon Bedrock Knowledge Bases now supports advanced parsing, chunking, and query reformulation*. Recuperado de https://aws.amazon.com/blogs/machine-learning/amazon-bedrock-knowledge-bases-now-supports-advanced-parsing-chunking-and-query-reformulation-giving-greater-control-of-accuracy-in-rag-based-applications/

Amazon Web Services. (2024g). *Build cost-effective RAG applications with binary embeddings in Amazon Titan Text Embeddings V2*. Recuperado de https://aws.amazon.com/blogs/machine-learning/build-cost-effective-rag-applications-with-binary-embeddings-in-amazon-titan-text-embeddings-v2-amazon-opensearch-serverless-and-amazon-bedrock-knowledge-bases/

Amazon Web Services. (2024h). *Streamline RAG applications with intelligent metadata filtering using Amazon Bedrock*. Recuperado de https://aws.amazon.com/blogs/machine-learning/streamline-rag-applications-with-intelligent-metadata-filtering-using-amazon-bedrock/

Amazon Web Services. (2024i). *Amazon Bedrock Samples - RAG Knowledge Bases*. Recuperado de https://github.com/aws-samples/amazon-bedrock-samples/tree/main/rag/knowledge-bases

Amazon Web Services. (2024j). *Chunking strategies for RAG applications*. En Amazon Bedrock Samples Documentation. Recuperado de https://aws-samples.github.io/amazon-bedrock-samples/rag/open-source/chunking/rag_chunking_strategies_langchain_bedrock/

Mitchell, D., Agarwal, K., & Pecora, C. (2024). *Access control for vector stores using metadata filtering with Amazon Bedrock Knowledge Bases*. Recuperado de https://aws.amazon.com/blogs/machine-learning/access-control-for-vector-stores-using-metadata-filtering-with-knowledge-bases-for-amazon-bedrock/

Normativas y Estándares ISO

International Organization for Standardization. (2022). *Information security, cybersecurity and privacy protection Information security management systems Requirements (ISO/IEC 27001:2022)*. Geneva, Switzerland.

International Organization for Standardization. (2013). *Information technology Security techniques: Information security management systems Requirements (ISO/IEC 27001:2013)*. Geneva, Switzerland.

International Organization for Standardization. (2018). *Guidelines for auditing management systems (ISO 19011:2018)*. Geneva, Switzerland.

Herramientas

Amazon Web Services. (2024k). *Boto3: AWS SDK for Python*. Recuperado de https://boto3.amazonaws.com/v1/documentation/api/latest/index.html

Amazon Web Services. (2024l). *AWS Cloud Development Kit (CDK)*. Recuperado de https://docs.aws.amazon.com/cdk/

Biggs, J. (2024). *factor_analyzer: Factor analysis in Python*. Recuperado de https://factor-analyzer.readthedocs.io/

Intuitem. (2024). *CISO Assistant Community: ISO 27001:2022 Framework YAML*. Recuperado de https://github.com/intuitem/ciso-assistant-community

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... Duchesnay, E. (2011). *Scikit-learn: Machine learning in Python*. Journal of Machine Learning Research, 12, 2825-2830.

scikit-learn developers. (2024a). *VarianceThreshold - Feature selection*. En scikit-learn Documentation. Recuperado de https://scikit-learn.org/stable/modules/generated/sklearn.feature_selection.VarianceThreshold.html

scikit-learn developers. (2024b). *PCA - Principal component analysis*. En scikit-learn Documentation. Recuperado de https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html